Numer zlecenia oraz nazwa i akronim projektu: *Freshness – Aplikacja wykorzystująca sztuczną inteligencję do oceny świeżości oraz analizy wartości odżywczych (makro- i mikroelementów oraz witamin) warzyw i owoców*	**Zleceniodawca:** *Brak*	**Zleceniobiorca:** *Zespół projektowy*
Zespół projektowy: *Kamil Różański* *Kacper Bednarek* *Paweł Centkowski* *Piotr Kinowski*	**Kierownik projektu:** *Różański Kamil*	
Nazwa dokumentu: *Dokument Założeń Wstępnych*	**Odpowiedzialny za dokument:** *Bednarek Kacper*	**Opiekun projektu:** *dr hab. inż. Marta Łabuda*

Historia dokumentu

Wersja	Opis modyfikacji	Rozdział / strona	Autor modyfikacji	Data
1.0	*Wstępna wersja*	*Całość*	*Bednarek Kacper*	*12.10.2026*

Opis etapu: Celem etapu jest udokumentowanie decyzji związanych z zainicjowaniem projektu (cele, kontekst, zakres systemu, wizja konstrukcyjna etc.).

Oczekiwane produkty: Dokument Założeń Wstępnych w postaci dokumentu o strukturze według poniższego szablonu i nazewnictwie zgodnym ze składnią **DZW-Gr*A*(*XYZ*)_v*0*** – gdzie *A* to numer porządkowy grypy; *X*, *Y*, *Z* to nazwiska poszczególnych członków, a *0* to numer wersji.

1. Opis problemu

Konsumenci często nie potrafią jednoznacznie ocenić, czy posiadane warzywa i owoce nadają się jeszcze do spożycia, a wczesne oznaki psucia się (przebarwienia, plamy, pleśń) bywają przeoczone, co zwiększa ryzyko zatruć pokarmowych. Jednocześnie informacje o wartościach odżywczych produktów (makro- i mikroelementach oraz witaminach) są rozproszone w tabelach i serwisach internetowych, a ich wyszukanie wymaga czasu, co utrudnia świadome i zdrowe odżywianie. Przedsięwzięcie polega na stworzeniu aplikacji mobilnej, która na podstawie zdjęcia rozpoznaje warzywo lub owoc, ocenia jego świeżość przy pomocy sztucznej inteligencji i prezentuje jego wartości odżywcze. Udziałowcami są użytkownicy końcowi (konsumenci), zespół projektowy odpowiedzialny za wytrenowanie modelu i wykonanie aplikacji oraz opiekun projektu nadzorujący jego realizację.

2. Cele systemu

Celem systemu jest zminimalizowanie ryzyka zatruć pokarmowych spowodowanych spożyciem zepsutej żywności oraz wsparcie użytkowników w świadomym i zdrowym odżywianiu poprzez szybki dostęp do informacji o posiadanych produktach. Po zrealizowaniu projektu powstanie działający prototyp aplikacji na Androida i iOS, wytrenowany model AI rozpoznający rodzaj produktu i jego świeżość oraz baza wartości odżywczych (witaminy, makro- i mikroelementy na 100 g). Mierzalnymi efektami są: poprawne rozpoznanie produktu w co najmniej 80% przypadków, poprawna ocena świeżości w co najmniej 75% przypadków, wyświetlenie danych odżywczych w czasie poniżej 10 sekund oraz responsywne, niezawieszające się działanie aplikacji. System jest przeznaczony dla każdego konsumenta – osób robiących zakupy, przechowujących żywność w domu i dbających o zdrowe odżywianie.

3. Kontekst systemu

System stanowi aplikację mobilną na Androida i iOS działającą w całości lokalnie na telefonie użytkownika, bez serwera i bez połączenia z Internetem. Aplikacja korzysta z aparatu i galerii urządzenia, a dane o wartościach odżywczych pochodzą z publicznej bazy USDA FoodData Central, importowanej jednorazowo do lokalnej bazy aplikacji. Występuje jedna kategoria użytkowników – użytkownik aplikacji, który bez zakładania konta ma dostęp do wszystkich funkcji, a jego zdjęcia i historia skanów pozostają wyłącznie na jego urządzeniu; liczba użytkowników nie jest ograniczona, ponieważ nie wpływa na działanie systemu. Na tle rozwiązań konkurencyjnych, takich jak FreshScan AI (ocena świeżości, lecz tylko na iOS i dla ok. 12 produktów), Fitatu czy MyFitnessPal (wartości odżywcze ze zdjęcia, lecz bez oceny świeżości, z płatnymi funkcjami AI i wymaganym kontem) oraz Google Lens (rozpoznanie produktu bez oceny świeżości i danych odżywczych), system wyróżnia się połączeniem tych funkcji w jednej darmowej aplikacji działającej offline.

4. Zakres systemu (funkcjonalność)

Aplikacja umożliwia wykonanie zdjęcia warzywa lub owocu aparatem albo wybór zdjęcia z galerii, rozpoznanie rodzaju produktu oraz ocenę jego świeżości (świeży / zepsuty) wraz z pewnością modelu – przy pewności co najmniej 90% wyświetlany jest komunikat „Świeży”, w przedziale 75–89% „Raczej świeży”, a poniżej 75% „Raczej zepsuty”. Dla rozpoznanego produktu prezentowane są makro- i mikroelementy oraz witaminy na 100 g; użytkownik może ręcznie poprawić wynik, gdy model się pomyli, wyszukać produkt bez skanowania oraz przeglądać lokalną historię skanów. Zakres obejmuje popularne warzywa i owoce dostępne w sklepach przez cały rok lub często sezonowo, a ostateczna lista zależy od dostępnych zbiorów danych. System z założenia nie rozpoznaje produktów egzotycznych i rzadkich (np. kumkwat, patison), nie wykrywa zepsucia niewidocznego na powierzchni, nie zastępuje oceny zmysłowej i nie posiada kont

użytkowników; pozostałe funkcje mogą zostać dodane w kolejnych wersjach. Warunkiem odbioru jest działający prototyp na Androida i iOS spełniający opisane miary sukcesu.

5. Wymagania jakościowe i inne

Główne wymagania koncentrują się na wydajności – wynik skanu musi pojawić się w czasie poniżej 10 sekund, a aplikacja musi być responsywna i nie zawieszać się. System musi cechować się niezawodnością dzięki pełnemu działaniu offline oraz ochroną prywatności, ponieważ zdjęcia i historia skanów nie opuszczają urządzenia, a aplikacja nie zbiera danych osobowych. Ważna jest również przenośność (jedna baza kodu dla Androida i iOS, działanie także na budżetowych smartfonach), elastyczność umożliwiająca podmianę modelu i rozszerzenie bazy o nowe produkty oraz przejrzystość wyniku poprzez wyświetlanie pewności modelu.

6. Wizja konstrukcyjna

System zostanie zrealizowany jako aplikacja mobilna we frameworku Flutter z jedną bazą kodu dla Androida i iOS, działająca w pełni lokalnie na urządzeniu. Architektura opiera się na warstwowej strukturze (UI, logika, dane) z lokalną bazą SQLite przechowującą wartości odżywcze z USDA FoodData Central oraz historię skanów. Rozpoznawanie realizuje model MobileNetV3-Large z dwiema głowicami (rodzaj produktu i świeżość), dotrenowany metodą transfer learning w Pythonie 3.12 z użyciem PyTorch i torchvision na darmowych GPU (Google Colab / Kaggle), a następnie wyeksportowany do formatu TensorFlow Lite z kwantyzacją INT8. Wybór lekkiego modelu działającego na telefonie gwarantuje szybkie działanie, pracę offline i brak kosztów utrzymania serwera.

7. Ograniczenia

Głównym ograniczeniem produktu jest działanie wyłącznie na telefonie, co ogranicza rozmiar modelu, a jakość wyniku zależy od zdjęcia (oświetlenie, ostrość, kąt) i opiera się tylko na wyglądzie zewnętrznym produktu. Liczba rozpoznawanych produktów jest ograniczona zakresem darmowych zbiorów danych, w szczególności zdjęć zepsutej żywności, a wartości odżywcze są wartościami uśrednionymi z bazy USDA. W wymiarze projektowym kluczowe są ramy czasowe (wykonanie do 1–2 tygodni przed końcem semestru zimowego), czteroosobowy zespół oraz limity darmowych zasobów GPU. Projekt nie posiada budżetu na płatną infrastrukturę chmurową, dlatego opiera się wyłącznie na darmowych narzędziach i otwartych danych.

8. Słownik pojęć

AI – sztuczna inteligencja
MobileNetV3 – lekka architektura sieci neuronowej do rozpoznawania obrazów na urządzeniach mobilnych
Transfer learning – dotrenowanie gotowego modelu na własnych danych
Dataset – zbiór opisanych zdjęć do trenowania i testowania modelu
Pewność modelu – prawdopodobieństwo (w %) przypisane przez model wynikowi
TensorFlow Lite – format do uruchamiania modeli AI na telefonach
Kwantyzacja INT8 – zmniejszenie precyzji modelu w celu zmniejszenia jego rozmiaru
Flutter – framework do tworzenia aplikacji na Androida i iOS
SQLite – lokalna, plikowa baza danych
USDA FoodData Central – publiczna baza wartości odżywczych żywności Departamentu Rolnictwa USA
Makroelementy – składniki mineralne potrzebne w większych ilościach (np. wapń, magnez, potas)
Mikroelementy – składniki mineralne potrzebne w małych ilościach (np. żelazo, cynk)